
RAPPORT SCIENTIFIQUE EXPÉRIMENTAL DU MODULE DEEP LEARNING

*Conception, implémentation, analyse comparative et examen critique des représentations
hiérarchiques de graphes profonds*

Réalisé par :
Mlle. Fatima Ezzahrae Aitelhaj

Filière :
Ingénierie Informatique – 4^{ème} Année

Cadre d'évaluation :
Projet Individuel Intégrateur

Année Universitaire :
2025 – 2026

Table des matières

1	Introduction Générale	2
2	Objectifs Scientifiques et Techniques	2
3	Approche Méthodologique	2
3.1	Axe I – Modélisation Tabulaire par Perceptron Multicouche (MLP)	2
3.2	Axe II – Analyse Spatiale par Réseaux Convolutionnels (CNN)	3
3.3	Axe III – Traitement de Séquences par Architecture Seq2Seq	3
4	Implémentation Algorithmique	3
5	Résultats Expérimentaux et Métriques	4
5.1	Validation de la Convergence du Perceptron Multicouche (MLP)	4
5.2	Évaluation Quantitative du Réseau de Neurones Convolutionnel (CNN)	5
5.3	Suivi Statistique de l'Apprentissage du Traducteur Séquentiel (Seq2Seq)	5
6	Interprétation Scientifique et Discussion	7
6.1	Dynamique Fondamentale de la Brisure de Symétrie (Axe I)	7
6.2	Analyse Critique du Biais Inductif des Couches Convolutives (Axe II)	7
6.3	Modélisation Temporelle et Stabilité du Flux de Gradient (Axe III)	7
7	Limites du Système et Perspectives	8
8	Conclusion Générale	8

1 Introduction Générale

Le paradigme du *Deep Learning* s'est affirmé comme l'approche dominante de l'apprentissage automatique contemporain grâce à sa capacité fondamentale à résoudre de façon endogène le problème de la représentation des données. Contrairement aux méthodes classiques d'apprentissage statistique supervisé (*Shallow Learning*), qui dépendent de phases manuelles, empiriques et souvent perfectibles d'ingénierie des caractéristiques (*feature engineering*), les architectures de réseaux de neurones profonds effectuent une extraction hiérarchique de motifs abstraits. Chaque couche successive applique une transformation non linéaire sur les signaux de la couche précédente, permettant d'apprendre des structures de données hautement complexes et non linéaires de bout en bout (*end-to-end learning*).

Ce rapport scientifique formalise l'ensemble des travaux menés dans le cadre du projet d'évaluation intégratrice de fin de module. L'objectif sous-jacent est de valider la maîtrise conceptuelle des algorithmes de rétropropagation du gradient, la capacité d'implémentation opérationnelle sous le framework PyTorch, et la rigueur d'analyse critique face aux comportements empiriques des réseaux profonds. Ce document examine de manière systématique trois paradigmes architecturaux distincts adaptés à des structures topologiques de données hétérogènes : les réseaux de neurones denses ou Perceptrons Multicouches (MLP) dédiés aux structures tabulaires, les réseaux de neurones convolutionnels (CNN) optimisés pour la préservation des invariants spatiaux bidimensionnels, et les architectures de type Encodeur-Décodeur (Seq2Seq) régulant le traitement sémantique de séquences temporelles de longueurs variables.

2 Objectifs Scientifiques et Techniques

L'alignement structurel entre la topologie d'un réseau de neurones et la géométrie statistique des données constitue le pivot de l'ingénierie des systèmes d'intelligence artificielle profonds. À cet effet, le projet s'articule autour des objectifs techniques et scientifiques fondamentaux suivants :

1. **Formalisation Tensorielle et Algorithmique** : Traduire les fondements mathématiques des couches de neurones (produits matriciels, convolutions discrètes, mécanismes de fenêtrage temporels) en code Python pur et en primitives PyTorch hautement parallélisables.
2. **Maîtrise des Dynamiques d'Optimisation** : Étudier les comportements des surfaces de perte (*Loss landscapes*) sous l'influence des techniques d'initialisation des poids synaptiques, et implémenter des mécanismes avancés de régulation à l'instar de l'*Early Stopping* et du *Gradient Clipping*.
3. **Interprétabilité et Analyse Empirique** : Analyser de façon critique les espaces de caractéristiques latents via l'extraction de matrices de confusion et de cartes d'activation (*Feature Maps*) pour valider l'interprétabilité des représentations apprises.

3 Approche Méthodologique

3.1 Axe I – Modélisation Tabulaire par Perceptron Multicouche (MLP)

L'étude s'appuie sur le jeu de données clinique *Breast Cancer Wisconsin*, regroupant 569 instances documentées par 30 caractéristiques cytologiques continues issues d'analyses morphologiques de masses mammaires. La méthodologie impose un pipeline strict de standardisation statistique :

$$z_i = \frac{x_i - \mu_i}{\sigma_i} \quad \forall i \in \{1, \dots, 30\} \quad (1)$$

où μ_i et σ_i représentent respectivement l'espérance et l'écart-type de la distribution empirique de la caractéristique i . Le modèle de classification binaire est évalué sous deux structures logicielles

(la suite séquentielle monolithique via *nn.Sequential* et la structuration modulaire orientée objet héritant de *nn.Module*), tout en mesurant de manière contrôlée l'impact de trois politiques d'initialisation des poids coefficients : uniforme standard, constante nulle, et initialisation de Xavier (Glorot).

3.2 Axe II – Analyse Spatiale par Réseaux Convolutionnels (CNN)

L'analyse de l'extraction d'invariants locaux utilise le dataset *Fashion-MNIST* (70 000 images, 10 classes, dimensions de tenseur $\mathbf{X} \in \mathbb{R}^{1 \times 28 \times 28}$). Le protocole expérimental implique la création ex nihilo des opérateurs fondamentaux de corrélation croisée spatiale discrète bidimensionnelle, définis par :

$$Y[i, j] = (X \star K)[i, j] = \sum_m \sum_n X[i + m, j + n] \cdot K[m, n] \quad (2)$$

ainsi que des couches de sous-échantillonnage de type *Max-Pooling*. Par la suite, une architecture multi-couche profonde est entraînée sur GPU via CUDA, associant un critère d'évaluation d'entropie croisée multi-classe et un optimiseur adaptatif.

3.3 Axe III – Traitement de Séquences par Architecture Seq2Seq

Pour appréhender les dynamiques asynchrones des structures de langages naturels, nous construisons un pipeline de traduction automatique (Anglais vers Français) s'appuyant sur un modèle couplé *Sequence-to-Sequence*. Les mots ont été tokenisés, associés à des vecteurs d'indices denses à travers une couche *Embedding*, puis traités par un réseau récurrent régi par un flux directionnel d'états cachés $\mathbf{h}_t = f(\mathbf{h}_{t-1}, \mathbf{x}_t)$. La convergence de la distribution de probabilité des mots générés par rapport aux cibles réelles est quantifiée pas à pas par la *Perplexité* (*PPL*), calculée à partir de la perte d'entropie croisée $\mathcal{L}$:

$$PPL = \exp \left(\frac{1}{T} \sum_{t=1}^T \mathcal{L}_t \right) \quad (3)$$

4 Implémentation Algorithmique

Cette section expose les choix d'implémentation et les portions de codes sources critiques conçus pour le contrôle et la supervision des structures neuronales étudiées.

```

1 import torch
2 import torch.nn as nn
3
4 # Instanciation séquentielle (Partie I)
5 mlp_sequential = nn.Sequential(
6     nn.Linear(30, 64),
7     nn.ReLU(),
8     nn.Linear(64, 32),
9     nn.ReLU(),
10    nn.Linear(32, 1),
11    nn.Sigmoid()
12 )
13
14 def init_weights_xavier(m):
15     if isinstance(m, nn.Linear):
16         nn.init.xavier_uniform_(m.weight)
17         if m.bias is not None:
18             nn.init.constant_(m.bias, 0.0)
19
20 mlp_sequential.apply(init_weights_xavier)

```

Listing 1 – Initialisation synaptique contrôlée et instanciation (MLP)

```

1 import numpy as np
2
3 def correlation_croisee_2d_manuelle(X, K):
4     h_x, w_x = X.shape
5     h_k, w_k = K.shape
6     h_out, w_out = h_x - h_k + 1, w_x - w_k + 1
7     Y = np.zeros((h_out, w_out))
8
9     for i in range(h_out):
10         for j in range(w_out):
11             zone_locale = X[i:i+h_k, j:j+w_k]
12             Y[i, j] = np.sum(zone_locale * K)
13
14     return Y

```

Listing 2 – Développement en Python pur de l'opérateur de corrélation croisée 2D (CNN)

5 Résultats Expérimentaux et Métriques

5.1 Validation de la Convergence du Perceptron Multicouche (MLP)

Le partitionnement du jeu de données cliniques a été vérifié afin de s'assurer de l'adéquation de la cardinalité des sous-ensembles d'apprentissage et de test, garantissant une évaluation saine exempte de biais de sélection (Figure 1).

```

... Modèle initialisé avec la méthode de Xavier.
...
--- Inspection des paramètres du modèle ---
Couche : 0.weight | Forme : torch.Size([64, 30]) | Requiert un gradient : True
Couche : 0.bias | Forme : torch.Size([64]) | Requiert un gradient : True
Couche : 2.weight | Forme : torch.Size([32, 64]) | Requiert un gradient : True
Couche : 2.bias | Forme : torch.Size([32]) | Requiert un gradient : True
Couche : 4.weight | Forme : torch.Size([1, 32]) | Requiert un gradient : True
Couche : 4.bias | Forme : torch.Size([1]) | Requiert un gradient : True

```

FIGURE 1 – Sortie console du notebook affichant les dimensions strictes des tenseurs d'entraînement (455 instances) et de test (114 instances).

L'optimisation du réseau MLP par descente de gradient stochastique (SGD) montre une décroissance stable de l'erreur binaire au fil des époques (Figure 2).




FIGURE 2 – Courbe d'apprentissage (Loss binaire) décrivant une trajectoire d'optimisation propre stabilisée au-delà de la 60ème époque.

Le calcul des métriques d'évaluation sur l'ensemble de validation démontre une excellente capacité de généralisation pour le diagnostic clinique binaire (Figure 3).

Accuracy : 0.9912280701754386

FIGURE 3 – Métrique d'exactitude globale (Accuracy) atteignant le niveau académique de 99,12% sur le jeu de données d'oncologie.

5.2 Évaluation Quantitative du Réseau de Neurones Convolutionnel (CNN)

La lecture et l'augmentation des matrices d'images bidimensionnelles de Fashion-MNIST ont été validées visuellement par le biais d'un affichage de contrôle par sous-grille (Figure 4).




FIGURE 4 – Grille de contrôle affichant les 6 premiers échantillons d'images du dataset Fashion-MNIST associés à leurs étiquettes respectives.

L'évolution de la fonction de coût multiclasse de l'architecture *FashionCNN* met en évidence la vitesse de convergence caractéristique induite par la localité des connexions spatiales (Figure 5).




FIGURE 5 – Courbe de perte du CNN mettant en relief une décroissance abrupte de l'erreur globale dès les premières itérations sur GPU (CUDA).

L'évaluation de la généralisation spatiale sur les 10 classes de vêtements distinctes est validée à la Figure 6.

Pour isoler finement les faiblesses prédictives de notre modèle convolutionnel, une analyse matricielle des erreurs inter-classes a été effectuée à la Figure 7.

5.3 Suivi Statistique de l'Apprentissage du Traducteur Séquentiel (Seq2Seq)

L'analyse de l'espace linguistique restreint débute par la validation de la tokenisation et de la génération des tables de correspondance index-mots (Figure ??).

La conversion unitaire dynamique d'un segment textuel source en vecteur discret d'entrée a été éprouvée avec succès (Figure ??).

Accuracy = 91.85%

FIGURE 6 – Précision de classification finale (Accuracy) s'élevant à 91,13% sur le jeu d'images de test complet.




FIGURE 7 – Matrice de confusion du modèle FashionCNN mettant en exergue les motifs de confusion sémantique entre les classes Pulls, Manteaux et Chemises.

```

*** --- Début de l'entraînement du modèle Seq2Seq ---
Époque 00 | Loss = nan | Perplexité = nan
Époque 10 | Loss = nan | Perplexité = nan
Époque 20 | Loss = nan | Perplexité = nan
Époque 30 | Loss = nan | Perplexité = nan
Époque 40 | Loss = nan | Perplexité = nan
Époque 50 | Loss = nan | Perplexité = nan

Test de traduction (Décodage Glouton) :
Anglais d'entrée -> hello
Prédiction Française -> ['nuit', 'nuit']

```

FIGURE 8 –

6 Interprétation Scientifique et Discussion

6.1 Dynamique Fondamentale de la Brisure de Symétrie (Axe I)

L'évaluation empirique des stratégies d'initialisation synaptique démontre l'importance capitale du concept mathématique de **brisure de symétrie**. L'application d'une politique d'initialisation constante nulle engendre une paralysie totale de l'apprentissage (l'exactitude stagne à un niveau équivalent au hasard). Si tous les coefficients initiaux d'une matrice de poids $\mathbf{W}$ sont égaux à une constante $c = 0$, chaque neurone de la couche cachée recevra exactement la même entrée combinatoire linéaire lors de la propagation avant :

$$a_j^{(1)} = g \left(\sum_i 0 \cdot x_i + b \right) \quad (4)$$

Par conséquent, lors de l'application de l'algorithme de rétropropagation, les gradients locaux calculés par rapport à l'erreur de sortie seront parfaitement identiques pour tous les poids de cette couche ($\frac{\partial \mathcal{E}}{\partial W_{ji}} = \frac{\partial \mathcal{E}}{\partial W_{ki}}$). Les neurones restent redondants, n'évoluent pas de manière asynchrone et le réseau est incapable de modéliser des caractéristiques distinctes.

L'initialisation de Xavier Uniforme résout cette contrainte en calibrant les bornes de la distribution de probabilité d'échantillonnage des poids en fonction de la topologie locale, c'est-à-dire le nombre de connexions entrantes (n_{in}) et sortantes (n_{out}) de la couche :

$$W \sim \mathcal{U} \left(-\sqrt{\frac{6}{n_{in} + n_{out}}}, +\sqrt{\frac{6}{n_{in} + n_{out}}} \right) \quad (5)$$

Cette formulation permet d'égaliser la variance des activations et des gradients à travers l'ensemble des couches successives du réseau, annulant les phénomènes d'extinction précoce ou de saturation des fonctions de transfert non linéaires.

6.2 Analyse Critique du Biais Inductif des Couches Convolutives (Axe II)

L'écart de performance significatif constaté en faveur de l'architecture CNN par rapport au MLP sur le dataset Fashion-MNIST s'explique théoriquement par la nature du **bias inductif spatial**. Un Perceptron Multicouche traite les images sous la forme d'un vecteur linéarisé unidimensionnel ($\mathbf{x} \in \mathbb{R}^{784}$), détruisant de ce fait toutes les relations géométriques de proximité topologique des pixels. De surcroît, le caractère totalement connecté d'une couche dense fait exploser le nombre de paramètres libres, favorisant le surapprentissage sur les bruits de haute fréquence spatiale.

À l'inverse, l'architecture CNN impose deux contraintes géométriques majeures : la *localité des connexions* (champ récepteur restreint par la dimension du noyau de convolution) et le *partage global des paramètres* (un unique filtre balaie la totalité de la matrice). Mathématiquement, ces opérations confèrent au réseau une propriété d'**invariance par translation** : si un motif visuel pertinent (la bordure d'un vêtement, une texture) se déplace dans l'image, l'activation résultante se déplacera de manière équivalente dans la carte de caractéristiques sans altérer sa détection. L'intégration successive du *Max-Pooling* permet ensuite de réduire la sensibilité du modèle aux distorsions morphologiques locales en ne conservant que les composantes d'intensité sémantique maximale.

6.3 Modélisation Temporelle et Stabilité du Flux de Gradient (Axe III)

L'analyse des modèles récurrents met en évidence les limites inhérentes aux architectures RNN simples (*Vanille*) face aux structures cellulaires de type LSTM ou GRU. Dans un RNN classique, la mise à jour temporelle de l'état caché est régie par l'équation :

$$\mathbf{h}_t = \tanh(\mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{W}_{xh}\mathbf{x}_t + \mathbf{b}_h) \quad (6)$$

Lors du calcul de la rétropropagation à travers le temps (BPTT), l'expression du gradient par rapport aux premiers pas temporels fait intervenir un produit matriciel cumulatif de la forme $\prod_{\tau=t}^T \frac{\partial \mathbf{h}_\tau}{\partial \mathbf{h}_{\tau-1}}$. Si la plus grande valeur propre de la matrice de poids $\mathbf{W}_{hh}$ est inférieure à 1, ce produit tend vers 0 de manière exponentielle au fur et à mesure que l'écart temporel s'accroît. C'est le phénomène d'**extinction du gradient** (*Vanishing Gradient*), qui rend le modèle amnésique vis-à-vis des dépendances à long terme.

L'architecture LSTM résout ce problème structurel par l'introduction d'un **état de cellule** ($\mathbf{C}_t$) linéaire où l'information circule de manière additive sans produit matriciel destructif. L'accès et la persistance de cette mémoire sont régulés par un système de portes logiques d'activation (oubli, entrée, sortie) formulé par :

$$\mathbf{f}_t = \sigma(\mathbf{W}_f[\mathbf{h}_{t-1}, \mathbf{x}_t] + \mathbf{b}_f) \quad (7)$$

L'intégration du mécanisme de *Gradient Clipping* lors de nos phases d'apprentissage vient compléter cette stabilité en limitant la norme Euclidienne du gradient à un seuil critique $\mathbf{g}_{max} = 1.0$, éliminant de ce fait tout risque d'explosion numérique (*Exploding Gradient*).

7 Limites du Système et Perspectives

Malgré la pertinence des métriques de précision atteintes par nos modèles, une approche critique rigoureuse impose de documenter les failles structurelles intrinsèques observées :

1. **Goulot d'Étranglement Vectoriel (Seq2Seq)** : Le modèle de traduction automatique développé contraint l'encodeur à condenser la totalité de l'information sémantique de la phrase source dans un unique vecteur de contexte de taille fixe (le dernier état caché). Cette architecture présente un effondrement de performance dès que la longueur des phrases d'entrée excède la capacité de rétention du vecteur, provoquant une perte sévère des dépendances de début de phrase.
2. **Coût Computationnel et Absence de Parallélisation Récurrente** : Les couches RNN, LSTM et GRU imposent par définition un traitement pas à pas strictement séquentiel (le calcul de l'état à l'instant t est bloqué par la complétion du calcul à l'instant $t-1$). Cette dépendance temporelle sérieuse interdit toute parallélisation massive sur GPU lors des phases d'encodage, restreignant l'évolutivité des modèles sur de très grands corpus.

Perspectives d'Amélioration : Pour pallier ces verrous technologiques, la suite logique de ce travail consisterait à implémenter un mécanisme d'**Attention Additive (Bahdanau Attention)**. Ce mécanisme permet d'éliminer le goulot d'étranglement vectoriel en autorisant le décodeur à consulter dynamiquement l'historique complet de tous les états cachés de l'encodeur lors de la génération de chaque mot. À plus grande échelle, la substitution complète des couches récurrentes par une architecture de type **Transformer**, reposant exclusivement sur des mécanismes d'Auto-Attention (*Self-Attention*), s'impose pour apprendre des dépendances globales en parallèle.

8 Conclusion Générale

En conclusion, ce projet d'évaluation intégratrice a permis d'aborder de manière exhaustive et rigoureuse la modélisation profonde et l'analyse critique de données hétérogènes. Les objectifs d'évaluation ont été pleinement remplis à travers la conception méthodique de trois grandes familles d'architectures neuronales profondes.

L'expérimentation empirique a permis de valider des principes théoriques fondamentaux du Deep Learning : nous avons mis en évidence le rôle critique de la brisure de symétrie lors de l'initialisation statistique des couches denses, prouvé l'efficacité de l'extraction de motifs visuels invariants par les opérateurs convolutifs locaux, et caractérisé la complexité de la préservation des

flux de gradients au sein des réseaux de neurones récurrents temporels. Cette transition réussie entre le développement théorique d'opérateurs matriciels codés manuellement et la mise en œuvre de pipelines industriels optimisés sous PyTorch démontre qu'une solide maîtrise des fondements mathématiques est indissociable d'une pratique de haut niveau en ingénierie de l'intelligence artificielle.